

基于动态语义网络分析的主题演化 路径识别研究

陈翔, 黄璐, 倪兴兴, 刘家润, 曹晓丽, 王长天

(北京理工大学管理与经济学院, 北京 100081)

摘要 当前, 学科演变更替加速, 交叉融合态势加剧, 如何快速准确地识别领域的研究主题、理清领域的发展脉络、追踪主题的演化路径及动向, 进而把握领域的研究前沿, 成为科研工作者亟待解决的关键问题。本文提出了一套基于动态网络的主题演化路径识别方法, 首先通过引入分段线性表示法和 Word2Vec 模型构建动态关键词语义网络, 之后利用社区发现算法识别动态网络中的社区, 并通过度量相邻时间段间的主题相似性来表现主题间的演化关系, 最终识别主题的演化路径。本文以信息科学领域为例开展实证分析, 在方法验证部分, 本文对比了分段线性表示法与平均时间划分法的分析结果, 同时, 还将本方法与 K-means 和 LDA 两大方法在主题识别中的效果进行了比较。本研究能为科研工作者以及战略决策者开展前瞻性科研活动提供重要的决策支持。

关键词 主题演化路径; 动态网络分析; 分段线性表示法; Word2Vec

Identifying Topic Evolutionary Pathways through Dynamic Semantic Network Analytics

Chen Xiang, Huang Lu, Ni Xingxing, Liu Jiarun, Cao Xiaoli and Wang Changtian

(School of Management and Economics, Beijing Institute of Technology, Beijing 100081)

Abstract: With the rapid development of science and technology, several disciplines have shown accelerating changes and intensified cross-fusion. In this context, an important problem researchers face is how research topics can be quickly and accurately identified, evolutionary pathways and trends can be tracked, and research frontiers can be subsequently comprehended. This paper therefore proposes a method for the identification of topic evolutionary pathways based on a dynamic network. First, the dynamic keyword network is constructed via introduction of the piecewise linear representation and the Word2Vec model. Second, a community discovery algorithm is used to identify the communities in the dynamic network, and the evolutionary relationship among topics is represented via measurements of the topic similarity between adjacent time intervals. Finally, the topic evolutionary pathway is identified. This study involves empirical analyses in information science. For validation of the methodology, the results obtained via using the piecewise linear representation method are compared with those obtained via the average time-division method and also with the effect of our method with K-means and LDA in topic identification. This study can therefore provide important decision support for researchers and strategic decision-makers to perform research activities aimed at progressing in the field of study.

Key words: topic evolution; dynamic network analysis; piecewise linear representation; Word2Vec

收稿日期: 2020-08-13; 修回日期: 2021-01-02

基金项目: 国家自然科学基金面上项目“基于复杂网络的全球创新研发主体组合识别与评估方法研究”(71774013)。

作者简介: 陈翔, 男, 1976 年生, 博士, 教授, 硕士生导师, 主要研究领域为数据挖掘、智能推荐; 黄璐, 女, 1984 年生, 博士, 副教授, 硕士生导师, 主要研究领域为文献计量分析、科技创新管理, E-mail: huanglu628@163.com; 倪兴兴, 女, 1997 年生, 硕士, 主要研究领域为文献计量分析; 刘家润, 男, 1999 年生, 本科, 主要研究领域为复杂网络和文献计量分析; 曹晓丽, 女, 1999 年生, 硕士, 主要研究领域为文献计量分析; 王长天, 男, 1998 年生, 硕士, 主要研究领域为复杂网络和文献计量分析。

1 引言

主题演化路径识别是指通过对以词语为表征的研究主题在时间序列上的发展、变化趋势以及不同主题之间的交互作用进行跟踪分析,揭示技术领域发展脉络和演化规律的研究^[1]。它可以帮助科研人员追溯具体学科领域的发展趋势,识别研究热点和可能的新知识增长点^[2];也可以为政府和企业制定学科和领域发展规划提供重要的情报支持^[3]。通常,主题的演化路径由“主题的前驱者—主题—主题的后继者”构成^[4],主题间的演化关系可以用主题间的相似度来度量,当相似度大于一定的阈值则被认为存在演化关系,即不同主题在相邻时间段交界处存在新生、成长、衰减、合并、分裂以及衰亡六种演化方式^[5]。

大量学者从网络分析和词频分析两方面入手开展主题演化路径识别研究,主要包括信息熵、引文分析、突发词分析和共词分析等方法^[6]。近年来,基于关键词网络的主题演化路径识别方法被学者广泛使用^[7]。例如,Katsurai等^[8]构建了动态共词网络,对心理学领域的主题演化过程进行分析;侯剑华等^[9]利用共词网络和聚类分析识别了我国哲学领域研究主题的演化过程。其中,如何准确识别关键主题是该类研究的核心^[10],大量学者已开展相关研究。例如,Song等^[11]学者使用马尔可夫随机场对关键词进行聚类进而识别主题;王曰芬等^[12]使用LDA(Latent Dirichlet Allocation)模型识别出知识流领域的主题;张巍等^[13]采用主题词簇法通过词表清洗与合并、模糊语义处理等步骤对主题词表进行深度处理,解决了主题词表存在噪音和冗余的问题,实现了清洗、巩固主题词表的目的;有助于生成更有意义的核心聚类^[14]。此外,社区发现算法逐渐兴起,展现出比传统聚类方法更大的优势^[15],例如,Blondel等^[16]提出的Fast Unfolding算法可在不事先确定主题数的情况下更准确地进行主题识别。

然而,当前研究还存在一些不足。首先,这些方法均假定关键词之间相互独立,未充分考虑关键词之间的语义关联关系^[17],影响了关键词相似度分析的准确性。例如,关系密切的关键词对因没有共同出现在同一篇文献而被忽略。其次,传统主题演化路径识别研究往往凭经验或按照简单平均的方法对时间段进行划分,缺少科学依据。例如,时间段

划分过长,大量主题在设定时间段内已完成演化;时间段划分过短,一个主题会被重复划分在多个时间段,导致主题割裂^[9],均无法科学呈现主题间的演化关系。

为有效挖掘关键词之间的语义关系,准确识别领域中的热点主题及发展趋势,本文提出了基于动态网络分析的主题演化路径识别方法。首先,引入分段线性表示法(piecewise linear representation, PLR)对时间段进行划分,并利用Word2Vec模型^[18]构建动态关键词语义网络来体现关键词之间的语义联系;其次,利用Fast Unfolding社区发现算法识别动态网络中的社区,并基于Z-Score方法识别所有社区的主题标签以代表某领域的研究主题;最后,通过度量相邻时间段间的主题相似性来表现主题间的演化关系,进而识别主题的演化路径。本文以信息科学领域为例开展实证分析,并对方法的有效性进行了验证。

2 方法框架

本文的方法框架如图1所示,包括动态关键词语义网络构建、基于社区发现的主题识别、主题演化路径识别及可视化三大部分。

2.1 动态关键词语义网络构建

2.1.1 数据收集与预处理

本方法首先从WoS(Web of Science)中下载特定领域的文献数据,并利用文本挖掘软件VantagePoint^①抽取关键信息,包括关键词、标题、摘要以及年份;之后,对抽取的数据进行预处理,主要包括:去除标题及摘要中的乱码、去除带有乱码的关键词以及关键词中的XML标签等^[5]。

2.1.2 基于分段线性表示法的时间段划分

本部分的目的是基于分段线性表示法对关键词序列进行时间段划分。首先,对关键词在等时间区间(月、季、年等)内的数量变化进行统计,得到一条有效的关键词数量序列,记为 $K=\{k_1, k_2, \dots, k_t, \dots, k_l\}$,如图2a所示,其中, k_t 表示某研究领域在第 t ($1 \leq t \leq l$)时间区间内的关键词数量。在统计单位时间内的关键词数量时,为了清除噪声并使语义相同的关键词不被重复统计,本文利用主题词簇法^[4]对关键词进行清洗(包括基于专家知识整合同义词、合并词干相同的词汇等)。

① VantagePoint是面向文献计量数据(如科技论文、专利以及学术项目申请书等)的文本挖掘与可视化软件。更多详情请访问官网:<https://www.thevantagepoint.com/>




图1 基于动态网络分析的主题演化识别方法框架

其次, 利用分段线性表示法将得到的关键词数量序列 K 拟合为首尾衔接的分段线性结构 K_{PLR} , 如图2b中的折线所示。

这里, K_{PLR} 表示关键词数量统计序列 K 的分段线性结构, 其表达式为

$$K_{\text{PLR}} = \{ L_1(k_1, k_2, \dots, k_{t_1}), L_2(k_{t_1+1}, k_{t_1+2}, \dots, k_{t_2}), \dots, L_i(k_{t_{i-1}+1}, k_{t_{i-1}+2}, \dots, k_{t_i}), \dots, L_s(k_{t_{s-1}+1}, k_{t_{s-1}+2}, \dots, k_{t_s}) \} \quad (1)$$

其中, $L_i(k_{t_{i-1}+1}, k_{t_{i-1}+2}, \dots, k_{t_i})$ 表示 K_{PLR} 中的第 i ($1 \leq i \leq s$) 个线段, 也是根据数据点 $k_{t_{i-1}+1}, k_{t_{i-1}+2}, \dots, k_{t_i}$ 拟合的线段 (即趋势段), 这条线段的起始时间为 $t_{i-1} + 1$, 终止时间为 t_i 。

图2b中, 折线的转折点便是本文要识别的趋势转折点, 用 TTP (trend turning points) 表示, 表达式为

$$\text{TTP} = \{ 1, t_1, t_2, t_3, \dots, t_n \} \quad (2)$$

其中, t_1 表示第一个线段结束时的时间节点; t_2 表




图2 分段线性表示示意图

示第二个线段结束时的时间节点。这些时间节点标志着主题演化趋势开始发生转折，依据这些趋势转折点可以划分时间段，

$$T = \{T_1, T_2, T_3, \dots, T_n\} \quad (3)$$

其中， T_1 表示起始时间点为1、终止时间点为 t_1 的时间段； T_2 表示起始时间点为 $t_1 + 1$ 、终止时间点为 t_2 的时间段；以此类推直到最后一个趋势转折点被划入时间段内。

在分段线性表示法中，表示分段数量的参数 s 的设置非常关键， s 越小会忽略越多的局部波动数据，导致较大的整体拟合误差；而 s 越大保留的局部波动数据越多，引入的噪声也越多。本文参考了陈虹枢^[19]的参数设置方法来平衡拟合的可靠性与趋势的可捕捉性。

首先，确定 s 的取值范围，求出每个 s 对应的均值根误差（root mean square error, RMSE）并存入均值根误差序列。在该序列中，随着 s 值的增大，均值根误差值不断减小。RMSE是用来衡量观测值与真值之间偏差的指标，可以更加直观地表现观测值对于真实值的拟合效果，本文用该指标来衡量分段线性拟合后的曲线与原曲线之间的误差，其计算公式为

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{t=1}^N (k_t - \text{PLR}_t)^2} \quad (4)$$

其中， k_t 表示原曲线上 t 时刻的点； PLR_t 表示拟合后曲线上 t 时刻的点； N 表示数据点的总个数。

其次，利用求导的方式，选取在RMSE不断减小过程中显著放缓的那一点，以其对应的 s 作为最优结果，即求出RMSE序列近似导数最大值所对应的 s 值。本文用 s_{AD} 表示最优分段数，其计算公式为

$$s_{\text{AD}} = \max \left| \frac{\Delta \text{RMSE}}{\Delta s} \right| \quad (5)$$

2.1.3 基于Word2Vec的词向量获取

划分好时间段后，本文先对各时间段内的摘要和标题文本进行分句和分词处理，然后将分词后的语句序列作为语料库输入到待训练的Word2Vec模型中，并选用skip-gram模型对语料进行训练，最后，将得到的关键词通过训练好的Word2Vec模型映射为词向量。由于该词向量是基于关键词与上下文之间的关系得出的，既包含每个词从上位词继承来的公有属性，也包含自身的私有属性，可以体现关键词的多重语义信息^[20]。Word2Vec模型训练过程如图3所示。




图3 Word2Vec模型训练示意图

2.1.4 构建动态关键词语义网络

本部分主要是构建动态关键词语义网络。首先, 基于关键词的时间信息将抽取得到的关键词分到划分好的时间段内, 并利用主题词簇法对每个时间段内的关键词进行清洗。

接下来, 依次在各时间段内, 利用清洗后的关键词与其对应的词向量构建关键词语义网络, 构建过程阐述如下:

(1) 定义某领域在时间段 T_i 内清洗后的关键词集为 $W^{T_i} = \{w_1^{T_i}, w_2^{T_i}, \dots, w_i^{T_i}, \dots, w_n^{T_i}\}$, 其中, $w_i^{T_i}$ 表示属于关键词集 W^{T_i} 的第 i 个关键词。

(2) 定义 G_{T_i} 为时间段 T_i 内的关键词语义网络, $G_{T_i} = \{V, E\}$, 其中, V 表示 G_{T_i} 的节点集合, 它是由 T_i 时间段内的关键词集 W^{T_i} 组成的; E 表示 G_{T_i} 的连边集合, 由于它是由 Word2Vec 模型生成的关键词向量之间的余弦值组成的, 可以体现关键词间的多重语义关系。例如, $w_1^{T_i}$ 和 $w_2^{T_i}$ 是关键词语义网络 G_{T_i} 中的两个节点, $w_1^{T_i}$ 对应的词向量为 $v_x = (x_1, x_2, x_3, \dots, x_n)$, $w_2^{T_i}$ 对应的词向量为 $v_y = (y_1, y_2, y_3, \dots, y_n)$, 则节点 $w_1^{T_i}$ 和 $w_2^{T_i}$ 之间的连边值为向量 v_x 与 v_y 之间的余弦值 $\cos(v_x, v_y)$, 计算公式为

$$\cos(v_x, v_y) = \frac{\sum_{i=1}^n x_i \times y_i}{\sqrt{\sum_{i=1}^n x_i^2} \times \sqrt{\sum_{i=1}^n y_i^2}} \quad (6)$$

最后, 所有时间段内的关键词语义网络组成了本文的动态语义网络 G , 计算公式为

$$G = \{G_{T_1}, G_{T_2}, \dots, G_{T_i}, \dots, G_{T_n}\} \quad (7)$$

其中, G_{T_i} 为时间段 T_i 内的关键词语义网络。

2.2 基于社区发现的主题识别

本部分将识别动态关键词语义网络中的主题。首先, 利用 Fast Unfolding 算法识别语义网络中的社区。**Fast Unfolding 是基于模块度最大化的社区发现算法, 模块度是衡量社区划分效果的指标, 可以度量社区内部连接的紧密度以及社区之间连接的稀疏度, 模块度越大, 社区划分的效果越好**^[21]。本文用 R 表示模块度, 计算公式为

$$R = \frac{1}{2A} \sum_{ij} \left[A_{ij} - \frac{N^i N^j}{2A} \right] \delta(M_i, M_j) \quad (8)$$

其中, A 表示网络中所有连边的权重之和; A_{ij} 表示节点 i 和节点 j 之间的连边权重; N^i 为节点 i 所有连

边的权重之和, N^j 为节点 j 所有连边的权重之和; $\delta(M_i, M_j)$ 用来表示节点 i 和节点 j 是否在同一社区, 如果在同一社区, 取值为 1, 否则, 取值为 0。

为了避免弱关联和负关联 (向量余弦值为负数) 的关键词对在识别社区时引入噪声, 本文参考曾庆田等^[17]的研究对构建的关键词语义网络进行适当剪枝, 去掉部分关系较弱关键词对之间的连边。本文将 δ 依次从 0 增至 0.5 (步长为 0.05), 利用 Fast Unfolding 算法识别 δ 对应剪枝后网络中的社区, 并计算最后的模块度。这里, 本文将模块度最大值对应的 δ 作为剪枝的阈值。识别出动态网络中的社区后, 参考 Wang 等^[4]的方法, 利用 Z-Score 指标为每个社区的内部节点排序, 选出 Z-Score 值最高的节点作为该社区的主题标签, 计算公式为

$$z_i = \frac{N_M^i - B/M^o}{\sqrt{Q/M^o - (B/M^o)^2}} \quad (9)$$

$$B = \sum_{j \in M} N_M^j \quad (10)$$

$$Q = \sum_{j \in M} (N_M^j)^2 \quad (11)$$

其中, z_i 表示社区 M 中第 i 个节点的 Z-Score 值; N_M^i 表示社区 M 的第 i 个节点与社区 M 其他节点连边的权重之和; M^o 表示社区 M 的节点数量; B 表示社区 M 内所有节点与其他节点连边的权重和的总和; Q 表示社区 M 中所有节点与其他节点连边的权重和的平方的总和。节点的 Z-Score 值越高, 说明该节点与社区内其他节点的关系越紧密, 越能代表整个社区。参考 Guimerà 等^[22]的研究, Z-Score 值大于等于 2.5 的节点可以作为社区的核心节点。

2.3 主题演化路径识别及可视化

本部分将识别主题的演化路径并进行可视化。首先, 基于对应社区之间的相似度识别主题之间的演化关系。核心节点是社区内最具代表性的节点, 也是社区发展变化的关键^[4]。因此, 本文利用核心节点度量社区之间的相似性, 定义 $t+1$ 时间段内的某个社区为 M_{t+1} , t 时间段内的某个社区为 M_t , 则 M_{t+1} 与 M_t 的相似度为 $HS(M_t, M_{t+1})$, 计算公式为

$$HS(M_t, M_{t+1}) = \text{Sim}(H(M_t), H(M_{t+1})) \quad (12)$$

其中, $H(M_t)$ 表示 M_t 中核心关键词节点集, $H(M_{t+1})$ 表示 M_{t+1} 中核心关键词节点集; $\text{Sim}(H(M_t), H(M_{t+1}))$ 表示 $H(M_t)$ 与 $H(M_{t+1})$ 之间的相似度。

考虑到主题之间的相似度很大程度上依赖于主题之间的语义相似性, 本文基于核心关键词节点的词向量, 并利用关键词节点对应的 Z-Score 值赋予

权重, 采用向量余弦值加权平均的方法度量 $\text{Sim}(H(M_t), H(M_{t+1}))$ 。为了统一量纲, 本文对每个社区的 Z-Score 值进行标准化处理。以社区 M_t 为例, 设该社区的核心关键词节点集 $H(M_t)$ 中的某个关键词为 W_t , 则 W_t 对应的 Z-Score 值的标准化过程为

$$Z'_{W_t} = \frac{Z_{W_t} - Z_{\min}}{Z_{\max} - Z_{\min}} \quad (13)$$

其中, Z'_{W_t} 表示关键词 W_t 对应的 Z-Score 标准化后的值, Z_{W_t} 表示 W_t 对应的 Z-Score 值; $Z_{\max}$ 表示标准化前 $H(M_t)$ 对应的 Z-Score 值中最大值, $Z_{\min}$ 表示标准化前 $H(M_t)$ 对应的 Z-Score 值中最小值。

对 Z-Score 值标准化处理后, $\text{Sim}(H(M_t), H(M_{t+1}))$ 的计算公式可以表示为

$$\text{Sim}(H(M_t), H(M_{t+1})) = \frac{1}{\sum (Z'_i \times Z'_{i+1})} \times \sum_{\substack{W_t \in H(M_t) \\ W_{t+1} \in H(M_{t+1})}} Z'_{W_t} \times Z'_{W_{t+1}} \times \cos(v_{W_t}, v_{W_{t+1}}) \quad (14)$$

其中, Z'_i 表示核心关键词节点集 $H(M_t)$ 对应的 Z-Score 值标准化后的集合; $\sum (Z'_i \times Z'_{i+1})$ 表示 $H(M_t)$ 对应标准化后的所有 Z-Score 值与 $H(M_{t+1})$ 对应标准化后的所有 Z-Score 值之间的两两乘积的总和; v_{W_t} 表示 W_t 由 Word2Vec 模型映射后的词向量; $\cos(v_{W_t}, v_{W_{t+1}})$ 则表示向量 v_{W_t} 与向量 $v_{W_{t+1}}$ 之间的余弦值。

计算得到主题间的相似度后, 可以剖析相邻时间段中两个主题之间的演化关系, 即确定每个主题的前驱者与后继者, 以及由“前驱者—主题—后继者”构成主题的演化路径。定义 $t+1$ 时间段内的某个社区为 M_{t+1} , 它的前驱者为 $\text{Pre}(M_{t+1})$, 则 M_{t+1} 为 $\text{Pre}(M_{t+1})$ 的后继者, $\text{Pre}(M_{t+1})$ 的表达式定义为

$$\text{Pre}(M_{t+1}) = \{ M_t | M_t \in G_t, \text{HS}(M_t, M_{t+1}) > \delta \} \quad (15)$$

其中, G_t 表示 t 时间段内的关键词语义网络; M_t 表示 G_t 中的某个社区; δ 为人工设定的阈值。

最后, 对整个领域的主题演化路径进行可视化。本文以矩形代表主题, 矩形上的文字代表主题标签, 矩形的高度与主题对应社区的节点数量成正比, 且同一时间段内的主题按照矩形的高度从大到小排成一行。再利用一条从前驱者指向主题的弧线表示主题间的演化关系, 弧线上标出两个主题之间的相似度, 不存在演化关系的主题将被描绘成浅灰色, 演化路径示意图如图4所示。

具体来看, $t-1$ 时间段内的主题 A 与 C 是 t 时间段内主题 D 的前驱者, 弧线上标了主题间的相似




图4 主题演化路径示意图

度, $t+1$ 时间段的主题 F 是 t 时间段内主题 D 的后继者。 $t+1$ 时间段内的主题 H 与其他主题不存在演化关系。

根据学者 Palla^[23] 的研究, 社区的发展过程可以分为六种模式: 新生、成长、合并、衰减、分裂以及衰亡。

(1) 新生: 在 t 时间段内不存在的社区, 在 $t+1$ 时间段内出现。

(2) 成长: 在 t 时间段内存在的社区, 继续在 $t+1$ 时间段内存在且社区节点增多。

(3) 合并: 两个或者多个存在于 t 时间段内的社区在 $t+1$ 时间段内合并为一个社区。

(4) 衰减: 在 t 时间段内存在的社区, 继续在 $t+1$ 时间段内存在且社区节点减少。

(5) 分裂: 存在于 t 时间段内的社区在 $t+1$ 时间段内分裂成两个或者多个社区。

(6) 衰亡: 存在于 t 时间段内的社区在 $t+1$ 时间段内消失。

2.4 方法验证

本文设计了定性与定量相结合的验证方法。在定性验证部分, 我们将本文的分析结果与权威期刊文献的结果进行了对比; 在定量验证部分, 本文既对比了分段线性表示法与平均时间划分法的分析结果, 又将本方法与 K-means 和 LDA 两大方法在主题识别中的效果进行了比较, 并将准确率、召回率和 F_1 值作为评价指标^[24], 用来验证本方法的有效性。相关指标计算公式为

准确率=

$$\frac{\text{正确抽取到与对应主题相匹配的关键词数量}}{\text{标准集中的关键词数量}} \quad (16)$$

召回率=

$$\frac{\text{正确抽取到与对应主题相匹配的关键词数量}}{\text{方法抽取到的所有关键词数量}} \quad (17)$$

$$F_1 = \frac{2 \times \text{准确率} \times \text{召回率}}{\text{准确率} + \text{召回率}} \quad (18)$$

3 实证分析

信息科学是一门典型的交叉学科,近年来该领域文献增长迅速,新的科学概念大量涌现^[25],这使得该学科的主题演化过程更加复杂,其主题演化路径识别研究更有意义。本文选择信息科学领域作为实证分析对象,参考Hou等^[25]学者的最新研究确定了信息科学领域的9种期刊,从WoS下载了2010—2019年10108条文献数据,如表1所示。

表1 信息科学领域期刊文献统计

期刊	文献数量
Scientometrics	3226
Information Research	1083
Journal of Informetrics	878
Information Processing & Management	801
Journal of Documentation	660
Journal of Information Science	594
Library & Information Science Research	406
Research Evaluation	372
Journal of the American Society for Information Science and Technology	891
Journal of the Association for Information Science and Technology	1197
总计	10108

通过Vantage Point软件提取得到31523个作者关键词,去除带有乱码的关键词和XML标签后,获得31276个有效关键词;之后,将有效关键词按月份划分为120个关键词子集,利用主题词簇法进行清洗,得到一个随时间变化的关键词数量序列。这里,本文以2018年11月的关键词子集为例来演示清洗过程,如表2所示。

表2 2018年11月的关键词清洗步骤(主题词簇法)

步骤	清洗方案	词数量
1	VP软件集成的自然语言处理模块获取原始词	410
2	去除数字、数字开头与结尾的词,如“step1”和“one way”,“several indices”	406
3	去除停词、介词与连词:英文常用词停词表、科技文献常用词停词表	399
4	去除泛义词、科技文献中的共性词,如“Research framework”“novel method”	392
5	基于专家知识整合同义词,如“co-word analysis”与“word co-occurrence analysis”	660
6	语义模糊匹配:合并词干相同的词汇,如“citation count”与“citation counting”,“information seeking”与“seeking information”	375

接下来,本文利用分段线性表示法中常用的三种方法(滑动窗口法、自上而下法以及自下而上法),对关键词数量序列进行分段线性拟合,并将参数 s 的取值范围设置为2到20^[19]。遵循第2.1.2节的分析步骤,可以得到三种方法对应的最优分段数目 s 及其对应的均值根误差RMSE。最后,利用综合加权平均法对三种方法的拟合结果进行评估。为统一量纲,本文对 s 及RMSE两个指标进行标准化处理,使其均处于0到1之间,标准化的过程为

$$a_s = \frac{a_i - a_{\min}}{a_{\max} - a_{\min}} \quad (19)$$

其中, a_s 表示某指标标准化后的值; a_i 表示该指标标准化前的值; $a_{\min}$ 表示所有指标的最小值; $a_{\max}$ 表示所有指标的最大值。然后,对标准化后的 s 和RMSE指标加权求和(本文认为这两个指标同等重要,权值均为0.5),并用作评估指标。三种方法的拟合结果如表3所示。

表3 三种分段线性表示法的分段拟合结果

方法	s	RMSE	s (标准化)	RMSE (标准化)	加权 平均值
滑动窗口法	6	64.2653	0.3333	0.1269	0.2301
自上而下法	8	62.9382	1	0	0.5
自下而上法	5	73.3984	0	1	0.5

为了平衡趋势可捕捉性和拟合可靠性,本文倾向于分段较少以及均值根误差较小的拟合方法^[19],故选择了加权平均值最小的滑动窗口法(取值0.2301),该方法的拟合结果如图5所示。

这里,信息科学领域被划分为6个时间段,各个时间段的起始点与终止点如表4所示。

本案例中的关键词集中有大量短语,如“Information Retrieval”“Citation Analysis”等,而Word2Vec模型不能直接得出这些短语的向量,因此,我们将短语形式的关键词转换为相应的驼峰形式进行模型训练,如将短语“network analysis”转换为“NetworkAnalysis”,并将关键词通过训练好的Word2Vec模型映射为相应的词向量。这里,我们参考Wang等^[26]的工作,将向量设置为300维,窗口大小设置为7,最小词频设置为3。之后,在每个时间段内构建关键词语义网络。首先,将关键词集进一步划分为6个时间段内的关键词子集,删除词频小于3的关键词(去除噪声关键词)并使用主题词簇法进行清洗,清洗后的各时间段的关键词数量如表5所示。




图5 关键词数量序列的分段线性拟合结果

表4 关键词数量序列的时间段

时间段编号	时间段起始点	时间段结束点
1	2010/01	2012/04
2	2012/05	2013/09
3	2013/10	2014/07
4	2014/08	2015/06
5	2015/07	2016/10
6	2016/11	2019/12

表5 各时间段内的关键词数量

时间段编号	时间段	关键词数量
1	2010/01-2012/04	3002
2	2012/05-2013/09	2608
3	2013/10-2014/07	2051
4	2014/08-2015/06	2207
5	2015/07-2016/10	3229
6	2016/11-2019/12	4499

其次，依次在每个时间段内计算关键词对应词向量之间的余弦值，并以余弦值作为元素构建关键词关系矩阵。基于此可得到6个关键词关系矩阵，作为关键词语义网络。由于篇幅原因，这里只展示2010/01-2012/04时间段部分关键词关系矩阵，如表6所示。

表6 2010/01-2012/04关键词关系矩阵(部分)

	Information Retrieval	Citation Analysis	Information Science	Social Network Analysis
Information Retrieval	1	0.1375	0.8014	0.2596
Citation Analysis	0.1375	1	0.2626	0.4854
Information Science	0.8014	0.2626	1	0.2199
Social Network Analysis	0.2596	0.4854	0.2199	1

得到动态关键词语义网络后，利用 Fast Unfolding 进行剪枝并识别网络中的社区，最终输出代表社区的关键词列表。整个动态网络共识别出154个社区，各时间段网络的剪枝阈值、社区数量以及对应的模块度如表7所示。

表7 各时间段内关键词语义网络的社区划分结果

时间段	剪枝阈值(δ)	社区数量	模块度
2010.01-2012.04	0.45	31	0.6333
2012.05-2013.09	0.40	25	0.5224
2013.10-2014.07	0.30	23	0.4576
2014.08-2015.06	0.35	23	0.4253
2015.07-2016.10	0.35	24	0.5347
2016.11-2019.12	0.30	28	0.4746
总计	—	154	—

这里需要为每个社区赋予主题标签。首先，利用 Python 语言为154个社区中的每个节点计算其相应的 Z-Score 值，选择社区中 Z-Score 值最大的节点作为该社区的主题标签，并以 Z-Score 值超过 2.5 的节点为该社区的核心节点。之后，基于社区的核心节点度量相邻时间段间的社区相似度，参考 Schwartz 等^[27]的研究，将主题相似度阈值 δ 设为 0.7，即相似度大于 0.7 的主题存在演化关系。图6显示了信息科学领域 2010—2019 年的主题演化路径图。

我们可以发现，近十年间信息科学领域存在明显的主题演化现象。例如，2013/10-2014/07时间段内的“Collaboration Analysis”（合作分析）、“Collaboration Network”（合作网络）、“Social Network Analysis”（社交网络分析）、“Co-authorship Net-




图6 信息科学领域主题演化路径图(2010—2019年)

work”（合著网络）以及“Network Analysis”（网络分析）五个研究主题融合为2014/08-2015/06中的“Network Analysis”（网络分析），体现了主题合并；2013/10-2014/07时间段内的“Text Mining”（文本挖掘）主题分裂成2014/08-2015/06中的“Text Mining”与“Social Media Analysis”主题，体现了主题的分裂；又如，2016/11-2019/12时间段内产生了新的研究主题“Big Data”（大数据），2015/07-2016/10时间段内的“Epistemology”主题在2016/11-2019/12中消失，这体现了主题的新生与衰亡；同时，“Citation Analysis”（引文分析）贯穿了整个过程，其对应社区的大小也在不断发生改变，体现了主题的成长和衰减。

基于图6所示结果，我们可将近十年信息科学领域的研究主题划分为计量、管理和技术三部分。
①计量维度包括文献计量、信息计量、科学计量以

及网络计量等定量化研究，如一直贯穿信息科学领域的“Citation Analysis”，以及演化过程中与其合并的“Academic Ranking”（学术排名）、“Author Ranking”（作者排名）等，它们是文献计量学中的常用方法，致力于对期刊、学者以及科学研究的影响性进行定量化评估。可以看出，定量化研究是信息科学领域的重要研究方向与必然趋势；②管理维度是管理学在信息科学领域进一步深化和拓展，如图中的“Knowledge Management”（知识管理）、“Document Management”（文档管理）及其演化出来的“Information Retrieval”（信息检索）等；③技术维度是指信息科学领域不断引入数学模型、计算机算法等工具展开新的研究，包括数学模型、深度学习等主题，如图中的“Text Mining”（文本挖掘）、“Text Clustering”（文本聚类）、“Machine Learning”（深度学习）以及“Scientific Model”（科学模型）

等。该维度的主题是信息科学领域重要的新兴趋势，应当予以重视。

下面，我们以“Citation Analysis”研究主题相关演化路径（图7）为例进行重点探讨，并与权威期刊文献的分析结果进行对比验证。

从图7可以看出，2010/01-2012/04时间段中有“Citation Analysis”“Academic Ranking”“Journal Impact Factor”（期刊影响因子）以及“Webometrics”（网络计量学）四个研究主题，在2012/05-2013/09时间段内融合为“Citation Analysis”，这说明越来越多的学术、期刊影响性以及网络计量学研究用到引文分析方法，使四个主题之间的关系越来越紧密，进而融合。我们的结论也与很多学者的研究相一致，例如，学者Vaio等^[28]明确指出，引文分析是评估期刊和学术研究的重要工具，并用引文分析研究经济学相关期刊的排名；同时，2014/08-2015/06中的“Text Mining”主题融入2015/07-2016/10中的“Citation Analysis”，例如，学者Kralj等^[29]明确提出通过结合文本挖掘技术与引文网络分析为研究问题带来了新视角，利用“Text Mining”构建新型的引文网络；此外，2014/08-2015/06时间段内的“Altmetrics”（替代计量学）和2015/07-2016/10的“Social Media Analysis”（社交媒体分析）均融入了“Citation Analysis”，这表明基于网络媒体文本的新式计量学为“Citation Analysis”带来了“新鲜血液”，例如，学者Sud等^[30]指出通过挖掘转发、评论等社交媒体关系可以准确地识别意见领袖。

接下来，本文采用传统的平均时间段划分法对主题演变的时间段进行划分，并对2010—2019年信息科学领域的主题演化路径进行描绘，结果如图8所示。可以明显看出，图8与图6相比丢失了很多

主题，如图6中2012/05-2013/09时间段内的“Technological Transition”（技术转型）、“Information Gain”（信息增益），2013/10-2014/07时间段内的“Citing Behavior”（引用行为）、“Concept Map”（概念图）以及2014/08-2015/06时间段内的“Technology Policy”（技术政策）、“Knowledge Organization System”（知识组织系统）等主题均没有在图8中出现，这也进一步体现出本文提出的分段线性法的优越性。

我们还将本方法与K-means和LDA两类方法同时进行对比，以验证本文在主题识别上的有效性。参照林江豪等^[24]的研究，我们首先依据信息科学领域专家意见建立一个标准“主题-关键词”集（标准集），作为各类方法分析结果的对照标准；其次，分别基于本文方法、K-means和LDA得出相应的关键词集，并把分析结果与标准集进行对比。由于篇幅原因，这里只展示部分结果，如表8所示。首先，我们邀请了5名信息科学领域专家从6个时间段内分别随机挑选2个主题，共得到12个研究主题（表8第2列）；然后，由专家确定与主题对应的关键词集（表8的第3列）；接下来，我们分别使用本文方法、K-means和LDA三种方法进行主题识别，结果如表8的第4~6列所示。

之后，我们以准确率、召回率和 F_1 值作为评价指标将三种方法的分析结果与人工建立的标准集进行比较，对比结果如图9所示。

从图9可以看出，本文方法分析结果所在的基本都在图的上部，这表明对于6个时间段内的12个主题，本文方法的3个验证指标值大多优于K-means和LDA方法，显示了本文提出的动态语义网络分析方法具有更好的主题识别效果。




图7 以“Citation Analysis”主题为主的演化路径图




图8 信息科学领域主题演化路径图(平均时间段划分法)

表8 主题词分析结果示例

时间段 编号	主题标签 (专家确定)	标准关键词集 (专家确定)	本方法获取的关键词集	K-means 获取的关键词集	LDA 获取的关键词集
1	Webometrics	Internet Search, Blogs, Social Media, Social Search, Web Search Engines, Web Documents, Multimedia, W3C, Social Clues, Wikipedia, YouTube, intranet, crowdsourcing, Wiki Map, Web2.0, Webometrics	Internet Search, Webometrics, Management Information Systems, PACIS, Blogs, Social Media, W3C, Free Online Scholarly Information, Social Search, Intelligent Agent, Social Clues, Topical Clues, Web Search Engines, Web Documents	Multimedia, TRECVID, Wikipedia, popular, YouTube, WWW, intranet, crowdsourcing, Wiki Map, MedlinePlus, Web 2.0, Website, wiki, Internet, Webometrics, interface, CSS, Online, Blogs	Resources, Html, Web Pages, Web Documents, Online, Media, Users, Social Media, Website, Ping, Blogs, Multimedia, WWW

4 结论与不足

本文提出了一种基于动态网络的主题演化路径识别方法,一方面,引入分段线性表示法对主题演变的时间段进行划分,解决了传统主题演化路径识别研究划分时间段不合理的问题;另一方面,基于Word2Vec模型构建动态网络,并利用社区发现算法在动态网络中识别主题,充分考虑了关键词之间的语义关系以使分析结果更加准确。

本研究也存在一些不足。首先,分段线性表示法仍可以继续改进,例如,最新的基于时序趋势的分段线性化算法,在数据集上展现了分段少、逼近性好等优点;其次,本文通过将短语形式的关键词转换为驼峰形式,对语料库中相应的关键词进行了替换处理,这样可能会因为改变语料库的文本结构而降低关键词向量识别的准确度,在未来的研究中可以考虑利用Phrase2Vec模型对关键词向量进行训练。




图9 主题识别的结果对比

参 考 文 献

- [1] 叶春蕾, 冷伏海. 基于共词分析的学科主题演化方法改进研究[J]. 情报理论与实践, 2012, 35(3): 79-82.
- [2] 焦红, 李秀霞. 基于研究主题的学科领域知识演化路径识别——以图书情报领域粗糙集为例[J]. 情报理论与实践, 2019, 42(3): 101-106.
- [3] 曲佳彬, 欧石燕. 基于主题过滤与主题关联的学科主题演化分析[J]. 数据分析与知识发现, 2018, 2(1): 64-75.
- [4] Wang X G, Cheng Q K, Lu W. Analyzing evolution of research

- topics with NEViewer: a new method based on dynamic co-word networks[J]. *Scientometrics*, 2014, 101(2): 1253-1271.
- [5] 宫小翠, 安新颖. 基于LDA模型的医学领域主题分裂融合探测[J]. *图书情报工作*, 2017, 61(18): 76-83.
- [6] 巴志超, 杨子江, 朱世伟, 等. 基于关键词语义网络的领域主题演化分析方法研究[J]. *情报理论与实践*, 2016, 39(3): 67-72.
- [7] 黄璐, 朱一鹤, 张巍. 基于加权网络链路预测的新技术主题识别研究[J]. *情报学报*, 2019, 38(4): 335-341.
- [8] Katsurai M, Ono S. TrendNets: mapping emerging research trends from dynamic co-word networks via sparse representation[J]. *Scientometrics*, 2019, 121(3): 1583-1598.
- [9] 侯剑华, 吕东博, 王鹏. 从硕士学位论文看我国科学技术哲学研究的转向——基于对硕士学位论文的计量分析[J]. *黑龙江高教研究*, 2014, 32(2): 7-10.
- [10] Ding W Y, Chen C M. Dynamic topic detection and tracking: a comparison of HDP, C-word, and cocitation methods[J]. *Journal of the Association for Information Science and Technology*, 2014, 65(10): 2084-2097.
- [11] Song M, Heo G E, Kim S Y. Analyzing topic evolution in bioinformatics: investigation of dynamics of the field with conference data in DBLP[J]. *Scientometrics*, 2014, 101(1): 397-428.
- [12] 王曰芬, 傅柱, 陈必坤. 基于LDA主题模型的科学文献主题识别: 全局和学科两个视角的对比分析[J]. *情报理论与实践*, 2016, 39(7): 121-126, 101.
- [13] 张巍, 汪雪锋, 朱东华, 等. 主题词簇方法研究[J]. *科学学研究*, 2013, 31(11): 1615-1622.
- [14] Porter A, Zhang Y, Sakurai S. Text clumping for technical intelligence[M]// *Theory and Applications for Advanced Text Mining*. Croatia: InTech Publishing, 2012.
- [15] Wallace M L, Gingras Y, Duhon R. A new approach for detecting scientific specialties from raw cocitation networks[J]. *Journal of the American Society for Information Science and Technology*, 2009, 60(2): 240-246.
- [16] Blondel V D, Guillaume J L, Lambiotte R, et al. Fast unfolding of communities in large networks[J]. *Journal of Statistical Mechanics: Theory and Experiment*, 2008, 2008(10): P10008.
- [17] 曾庆田, 胡晓慧, 李超. 融合主题词嵌入和网络结构分析的主题关键词提取方法[J]. *数据分析与知识发现*, 2019, 3(7): 52-60.
- [18] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[OL]. (2013-09-07). <https://arxiv.org/pdf/1301.3781.pdf>.
- [19] 陈虹枢. 基于主题模型的专利文本挖掘方法及应用研究[D]. 北京: 北京理工大学, 2015.
- [20] 王飞, 谭新. 一种基于Word2Vec的训练效果优化策略研究[J]. *计算机应用与软件*, 2018, 35(1): 97-102, 174.
- [21] Newman M E J. Communities, modules and large-scale structure in networks[J]. *Nature Physics*, 2012, 8(1): 25-31.
- [22] Guimerà R, Sales-Pardo M, Amaral L A N. Classes of complex networks defined by role-to-role connectivity profiles[J]. *Nature Physics*, 2007, 3(1): 63-69.
- [23] Palla G, Barabási A L, Vicsek T. Quantifying social group evolution[J]. *Nature*, 2007, 446(7136): 664-667.
- [24] 林江豪, 周咏梅, 阳爱民, 等. 结合词向量和聚类算法的新闻评论话题演进分析[J]. *计算机工程与科学*, 2016, 38(11): 2368-2374.
- [25] Hou J H, Yang X C, Chen C M. Emerging trends and new developments in information science: a document co-citation analysis (2009-2016)[J]. *Scientometrics*, 2018, 115(2): 869-892.
- [26] Wang Y, Liu Z, Sun M. Incorporating linguistic knowledge for learning distributed word representations[J]. *PLoS One*, 2015, 10(4): e0118437.
- [27] Schwartz R, Reichart R, Rappoport A. Symmetric pattern based word embeddings for improved word similarity prediction[C]// *Proceedings of the Nineteenth Conference on Computational Natural Language Learning*. Stroudsburg: Association for Computational Linguistics, 2015: 258-267.
- [28] Vaio G D, Weisdorf J L. Ranking economic history journals: a citation-based impact-adjusted analysis[J]. *Cliometrica*, 2009, 4(1): 1-17.
- [29] Kralj J, Valmarska A, Robnik-Šikonja M, et al. Mining text enriched heterogeneous citation networks[C]// *Proceedings of the Pacific-Asia Conference on Knowledge Discovery and Data Mining*. Cham: Springer International Publishing, 2015: 672-683.
- [30] Sud P, Thelwall M. Evaluating altmetrics[J]. *Scientometrics*, 2014, 98(2): 1131-1143.

(责任编辑 王克平)