

● 巴志超, 杨子江, 朱世伟, 王 蕾 (山东省科学院 情报研究所, 山东 济南 250014)

基于关键词语义网络的领域主题演化分析方法研究

摘 要: 有效揭示领域中主题的浮现机理及发展轨迹, 对学科、领域未来发展态势进行预测和战略决策具有重要意义。文章提出一种基于关键词语义网络的领域主题演化分析方法。首先, 通过引入浅层神经网络语言模型 word2vec 对领域文献的题名、摘要进行建模学习, 将关键词表示成语义级别的词向量结构; 其次, 在建模基础上, 结合 Equivalence 共现系数进行关键词语义相似度计算并构建关键词语义网络; 最后采用社会网络分析方法从合著网络、共现网络等角度对领域主题进行演化特征分析。实验表明: 该方法能够有效地识别领域的热点主题及发展趋势。

关键词: 语义网络; 神经网络语言模型; 词向量; 主题演化分析; 语义模型

Abstract: Reveal of emergence mechanism and development track of theme in the field have important significance in predication of future development trend and strategic decision-making for discipline and domain. This paper presents a new theme evolution analysis method based on keywords semantic network. Firstly, titles and abstracts are modeled to indicate word vector structure for keywords based on neural network language model—word2vec. Secondly, through the study of word distribution and combination of Equivalence co-occurrence coefficient, the semantic association of keywords is calculated to build up the semantic network. Finally, using social network analysis method, the paper analyzes the evolution characteristics of domain theme from collaboration network and co-occurrence network. The experiments demonstrate that the proposed approach can accurately identify the hot topics and development trend for disciplinary field.

Keywords: semantic network; neural network language model; term vectors; theme evolution analysis; semantic model

领域主题是指某一研究领域内的主要研究热点和研究重心, 对领域主题进行挖掘及演化分析主要是利用领域相关文献中的作者、关键词等知识单元之间的语义关系对文献集合进行分析, 进而发现研究主题, 并根据不同时间段内主题的新生、消亡、分裂等演化过程来探测主题的演进路径, 以把握该学科领域的发展态势及未来走势。探测和追踪学科、领域中主题的形成和演化规律, 理清其发展脉络, 是应对信息大爆炸时代情报危机的有效途径, 也是指导、制定战略决策和发展计划的迫切要求^[1]。

针对主题演化分析方法的研究, 相关学者已经开展了大量的研究工作。目前, 常采用的主要方法有基于信息熵^[2-4]、基于词频分析^[5-6]、基于突发词共词分析^[7-8]以及基于引文分析方法^[9]等。由于关键词是文献核心内容的浓缩和提炼, 高度概括了文献的基本内容^[10]。较文献中其他知识单元而言, 关键词更能直观地反映出文献的主要内容及作者研究主题, 因而较多的研究利用文献资源中的关键词集合来研究领域主题的演化规律分析。然而, 基于传统词频或共现词频的分析方法, 假定作者的关键词之间相互独立, 未考虑关键词之间的语义关联信息, 因而不能很好地刻画领域主题之间的相似性, 无法有效地探测和追踪主题的演变过程。

为有效挖掘关键词之间的语义关系, 准确识别领域中的热点主题及发展趋势, 本文在传统共现分析方法的基础上, 提出一种基于关键词语义网络构建的领域主题演化分析方法。通过深度学习模型 word2vec 对领域相关文献进行建模学习, 将文献中的关键词表示成语义级别的单词特征向量。通过 Pearson 相关系数来计算关键词之间的相关程度, 并对共现的关键词采用强度指标 Equivalence 系数进行量化实现加权处理。最后选取信息检索研究领域的相关文献作为对象进行实验, 采用社会网络分析方法从合著网络、共现网络等角度对领域主题进行演化特征分析。

1 相关工作

基于信息熵方法进行主题演化分析主要是结合信息熵变化理论对领域主题研究结构分布进行计量分析, 通过计算不同时间段内主题的信息熵值来探测主题的演变过程。如 Kim 等^[11]采用信息熵方法分析韩国与中国的大学、行业以及政府之间在农业科研与专利信息方面知识传播中的不确定性, 以揭示两国之间存在的共性和差异。安新颖^[12]采用改进的信息熵方法对主题进行遴选, 并采用战略坐标分析描绘干细胞领域主题演化趋势。由于学科主题演化过程是一个具有耗散结构特性的综合系统^[13], 将信息熵概念

引入主题演化计量分析中,能够有效地衡量主题演化趋势是否具有连续、有序等特性。基于词频分析方法是文献计量研究中比较常用的一种方法,该方法通过统计领域文献中关键词或主题词出现的频次来判别领域的研究热点、知识结构和发展趋势。如孙雨生等^[5]采用词频分析法揭示国内数字图书馆个性化服务研究主题及其演化状况、发展趋势。李长玲等^[6]以知识网络研究领域为例,从合著网络、共词网络以及时间—作者—关键词3模共现网络来分析该领域主题的演化轨迹。然而基于这种方法只考虑词频的变化来刻画主题的演变过程,未考虑词对之间更深层次的语义关系。另外,基于词频统计分析方法也忽略词自身的生长规律,在分析科学前沿和演化过程时存在一定的局限性。

为此,相关学者提出基于突发词的共现分析方法,根据不同时间段内词频分布情况获取词频变化率较高的词作为突发词,通过不同阶段突发词的共现及分布等特性进行主题热点发现及演化趋势分析。如Kleinberg^[7]提出的突发词检测算法,通过概率机对不同时段词的频次进行建模,发现词频增长率较高的词作为突发词,并根据突发词在各时段的密度定义其状态层次,进而用于探测新的研究热点。Ke等^[8]应用该突发检测算法揭示了ACM数据库中信息可视化领域的研究热点以及发展趋势。王莉亚^[9]提出一种基于信息熵的时间序列中突变点识别方法,通过获取关键词词频突变点进行演化阶段划分,来揭示流域水资源管理领域的主题特征和发展趋势。基于这种方法考虑了词自身的变化及发展的阶段性,但提出的突发词检测方法中最优时间序列的确定受参数设置的限制,且算法基于回溯数据,需要一定历史时间积累的文档作为分析基础。基于引文分析法是采用分析对象之间的相互关联信息来探测领域的研究主题和演化趋势。如赵蓉英^[10]等通过文献共引分析和因子分析法对高被引论文的被引轨迹及其共现网络进行分析,得出科学计量学在各发展阶段的主流研究领域。Small^[11]利用共引簇、可视化和簇串信息从多角度探索研究领域的变化与发展。基于上述方法在一定程度上能够发现领域主题的发展脉络与线索,并对未来的发展趋势进行预测。然而,基于以上几种方法的较多研究只考虑关键词之间的共现性进行主题演化分析,忽略了关键词之间的语义关联信息。为此,本文提出一种基于关键词共现与语义关联相结合的主题演化分析方法。

2 基于 word2vec 的关键词语义建模

word2vec模型是由Mikolov等^[12]提出的用于将单词转化成向量的深度学习工具,该模型属于浅层神经网络语言

模型(Neural Network Language Model, NNLM)的一种。通过该模型进行训练,可以将每个关键词映射成 K 维实数向量的形式,然后通过计算关键词之间的距离(如余弦距离、欧式距离等)来判断它们之间的语义相似度。而基于关键词共现分析方法是将每个关键词表示成 $0 \sim 1$ 向量的形式,在该向量中,如果与其他的关键词在同一篇文献中同时出现,则在相应的位置使用1进行表示,否则为0。基于此存在两个问题:①关键词之间被孤立地看成向量中两个不同的维度,它们之间被认定相互独立。②关键词向量会随着词特征集合的增大而增大,从而导致向量较为稀疏且高维^[13]。基于word2vec模型进行语义建模,能够摒弃这种 $0 \sim 1$ 稀疏表示方法,而采用关键词低维实值的分布进行表征。如将关键词“信息检索”表示为:[0.843, 0.621, 0.516, 0.459, ..., 0.172]。word2vec模型为计算词的向量表示提供了一种有效的连续词袋(Continuous Bag-of-Words, CBOW)和Skip-gram架构的实现。本文主要基于Skip-gram模型,并采用Hierarchical Softmax方法进行优化训练。

Skip-gram模型主要是基于当前词对其上下文语境进行有效预测,利用语言具有递归性的特点实现跳跃组合,将原本不相邻的切分单位组成串,从而降低数据稀疏带来的负面影响,Skip-gram模型架构见图1。从图中可以看出,Skip-gram模型主要预测概率 $p(w_i | w_t)$,其中, $t-c \leq i \leq t+c$, c 表示决定上下文窗口的参数, w_t 为当前词。对于给定的词序列 $w_1, w_2, w_3, \dots, w_T$,Skip-gram模型的训练目标是使公式(1)的值达到最大化:

$$\frac{1}{T} \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log p(w_{t+j} | w_t) \quad (1)$$




图1 Skip-gram模型架构

使用当前词 w_t 预测窗口大小为 c 的上下文时, c 值越大,则需要考虑的上下文因素就越多,计算得到的结果越精确,但相应的训练时间会增加^[14]。Skip-gram模型中,每个关键词 w 都有两个需要学习的参数向量,输入向量 μ_w 和输出向量 ν_w 。设字典的大小为 N ,给定关键词 w_j ,正确预测关键词 w_i 的概率为:

$$p(w_i|w_j) = \frac{\exp(\mu_{w_i}^T \nu_{w_j})}{\sum_{n=1}^N \exp(\mu_n^T \nu_{w_j})} \quad (2)$$

然后采用随机梯度下降的方法对目标函数进行训练,生成基于 Hierarchical Softmax 表示的上下文向量,通过余弦或欧式距离来计算词语之间的语义相似度。

3 关键词的语义网络模型构建

进行领域主题挖掘及演化趋势分析时,需要先计算关键词之间的关联强度并构造语义矩阵形式,再采用社会网络分析方法进行内容分析。基于关键词共现与语义关联相结合的主题演化方法流程是:首先确定学科领域需要分析的数据集并进行预处理,其次对获取的数据集按指定字段进行抽取,并分别进行频次统计分析与 word2vec 模型语义建模,然后对统计分析结果构建共现矩阵,对语义建模结果采用 Pearson 相关系数进行关键词对相关性计算,最后构造复合权值网络,并采用社会网络分析方法进行主题演化分析,见图 2。




图2 共现与语义关联相结合的主题演化流程

1) 数据处理。本文主要针对信息检索领域的主题热点及演化趋势进行分析,将从期刊数据库导出的 EndNote 格式题录数据进行分词和停用词过滤处理,关键词不进行分词处理。分词方法是将抽取的作者关键词集作为自定义词典,采用中国科学院 ICTCLAS 系统进行分词。采用文献题录统计分析工具 SATI^[3]进行字段抽取和频次统计分析,并按照不同时间段对数据进行限定,生成相应的频次统计文档,以及获取文献中的题名、摘要及关键词进行 word2vec 语义建模。

2) 共现矩阵构建。由于构建的二值/多值矩阵中统计的原始词对频次是绝对值,难以反映关键词之间真正的相互依赖程度。同时,多值矩阵中存在的频次悬殊数据以及较多的零值会对统计结果造成影响,因此,引入相对强度指标 Equivalence 系数^[4]对词对频次进行包容化处理,将多值矩阵转化为元素值在 [0, 1] 之间的相关矩阵,计算如公式 (3) 所示:

$$E_{ij} = \frac{N_{ij}^2}{N_i * N_j} \quad (3)$$

式中, N_i 、 N_j 分别表示关键词 i 和 j 的频次; N_{ij} 表示关键词 i 和 j 的共现频次。

3) 词对相关性计算。通过 word2vec 模型进行关键词语义建模后,获得每个关键词的词向量表示 $w_i = (S_{i,1}, S_{i,2}, \dots, S_{i,k})$, 其中 k 表示与关键词 w_i 最相似的 k 个词, $S_{i,k}$ 表示第 k 个关键词与 w_i 之间的余弦值。然后采用 Pearson 相关系数 (Pearson Correlation Coefficient, PCC)^[1]来计算关键词之间的语义相关性。关键词 w_i 与关键词 w_j 的词向量之间的相关性 $\rho(w_i, w_j)$, 计算公式如下:

$$\rho(w_i, w_j) = \frac{\sum_k (S_{i,k} - \bar{S}_i)(S_{j,k} - \bar{S}_j)}{\sqrt{\sum_k (S_{i,k} - \bar{S}_i)^2} \sqrt{\sum_k (S_{j,k} - \bar{S}_j)^2}} \quad (4)$$

式中, $\bar{S}_i$ 、 $\bar{S}_j$ 分别表示关键词 w_i 、 w_j 与其所有相关词之间余弦的平均值。计算得到的 $\rho(w_i, w_j)$ 值越大,说明关键词 i 和 j 之间越相关。

4) 复合权值网络的构建。基于共现分析方法只能从关键词的频次或共现频次角度来反映领域主题的热点或突变程度,在聚焦领域主题的发展趋势时,需要进一步进行关键词之间的语义关联分析,才能有效地揭示知识的微观演化轨迹^[8]。为此,本文将关键词共现与语义关联建模方法相结合,通过构造复合权值的方式来度量关键词之间的语义关联性。最终关键词 w_i 与 $w_j (i \neq j)$ 之间的语义相关度 $S(w_i, w_j)$ 计算如公式 (5) 所示:

$$S(w_i, w_j) = \rho(w_i, w_j) + \lambda E_{ij} \quad (5)$$

式中,参数 λ 表示关键词共现值的调节因子, λ 的取值范围为 0 ~ 1 之间。由于对 λ 的取值无任何经验,本文的实验取 $\lambda = 0.5$ 。

4 领域主题演化规律分析

4.1 数据来源

根据布拉德福文献离散理论“大多数关键文献通常集中发表于少数的核心期刊”^[9],因此,本研究的实验数据主要选取《中文社会科学引文索引》(CSSCI)作为数据源,获取信息检索研究领域的期刊文献。CSSCI 遵循文献计量学规律,采取定量与定性评价相结合的方法从中文人文社会科学学术性期刊中精选出学术性强、编辑规范的期刊作为来源期刊。研究以(主题 = “信息检索” or 主题 = “文献检索” or 主题 = “信息存储与检索” or 主题 = “检索模型” or 主题 = “语义检索”)为检索式,检索发表时间在 2003—2014 年时间段内的文献共 3120 篇,去除综述、评论、报告及其他类型文献,并根据文献的标题及发表年份进行去重处理,最终获得期刊论文共 2947 篇,涉及作者 4095 位,关键词 6184 个。

为简化统计过程以及减少低频词对统计分析的干扰,

首先对近义词如“ontology”与“领域本体”、“个性化”与“个性化服务”等进行合并,并剔除无实际意义词如“信息”、“高校”、“现状”等关键词。然后采用关键词 g 指数方法^[2] 获取不同年份的高频词进行语义关联分析。关键词 g 指数定义:某一个研究主题关键词的数量分值为 g , 当且仅当此研究主题的关键词总量 N 中,有 g 个关键词其累计出现频次不少于 g^2 次^[2]。基于该方法获取分析对象,即考虑了关键词的词频对热点主题的贡献程度,同时还衡量了主题文献的数量和学术影响。

4.2 数据结果分析

4.2.1 作者关键词向量建模 根据下载的题录信息,对所有年份文献中的题名、摘要及关键词进行建模,采用 word2vec 嵌入模型进行训练,生成词向量库文件,以获取关键词的词向量表示形式。对于模型的训练参数设定:最相似词维度 topNSize = 40, 上下文窗口大小参数 window = 10, 设定高频词亚采样阈值参数 sample = $1e-3$, 并采用层次 Softmax 和 Skip-gram 算法得到 hs = 1、cbow = 0, 基于 Pearson 相关系数来计算关键词之间的相关度。同时,对文献中的关键词进行词频统计,并根据公式(3)构造相似矩阵,最后结合公式(5)计算关键词之间的语义相关度 $S(w_i, w_j)$ 并构建语义网络,见表1。表1中显示部分关键词之间的语义相关度,为进一步突出不同关键词之间的语义相关性,设定阈值 $\xi = 0.1$, 小于该值时计为0值。从表1中可以看出,通过将共现与语义关联方法相结合,使得关键词“信息检索”与“本体”、“检索模型”以及“信息组织”具有较高相关性,而关键词“文献计量”与其他关键词的语义相关性较低。另外,关键词“信息检索”与“领域本体”之间以及“领域本体”与“语义检索”之间的相关度都大于0.5,而“信息检索”与“语义检索”之间的相关度为0.346,说明该方法计算得到的相关度不具有传递性,而是从语义和共现的角度计算得到。

表1 关键词间的语义相关度(部分)

关键词	信息检索	领域本体	搜索引擎	语义检索	检索模型
信息检索	1				
领域本体	0.511	1			
搜索引擎	0.217	0	1		
语义检索	0.346	0.561	0.145	1	
检索模型	0.548	0.429	0.103	0.215	1
文献计量	0	0	0.214	0	0.146
可视化	0.279	0	0	0.373	0.215
信息组织	0.452	0	0	0.357	0
个性化	0.195	0.124	0.101	0.254	0.202
文献检索	0.213	0.138	0	0.519	0.174

采用社会网络分析软件 Ucinet 对构建的关键词语义网络进行分析。见图3。图3中节点的位置越居中以及面积

越大,说明该关键词越核心,越能表示该领域研究的热点。关键词之间的语义关系表征节点之间的连线,连线越粗说明关系越紧密,关键词之间的相关性就越大。从图3中可以看出,2003—2014年我国信息检索领域主要围绕基于本体等方法的信息检索模型构建、语义检索方法、可视化技术、个性化服务以及文献检索等方面开展研究。




图3 2003—2014年信息检索领域关键词语义网络图

4.2.2 信息检索领域主题演化分析 为进一步探测和追踪主题的演化趋势,采用关键词 g 指数获取不同年份内频次较高的关键词,并计算同年份关键词间的相似度。通过对关键词演进的动态跟踪,可有效揭示该领域知识发展变化及其相互作用的特征与规律性,能更好地发现可能的新知识增长点,追溯学科的发展轨迹^[2],见图4。其中节点圆形表示“年份”,方形表示“关键词”。




图4 信息检索领域主题演化网络图

从图4中可以看出,信息检索模型、数字图书馆、文献检索以及语义检索的演化机制处于网络中心位置,说明这些主题是近几年主要的研究热点,这与图3显示的信息检索领域整体关键词语义网络一致。关于该领域主题演化规律呈现以下特点:①信息检索领域研究内容不断深入,部分主题呈现动态变化。对于信息检索技术的研究逐

从图 6 中可以看出,该领域作者合著关系演进规律具有以下特点:①该领域核心作者及合作团队基本形成。图中圆圈内是该领域的主要研究作者,通过 Ucinet 社会网络软件进行中心性分析,计算得到该网络的平均点度中心度为 1.093,其中,作者王知津、邱均平、韩毅、陆伟、章成志等作者的点度中心度最高,这些作者在该领域基本每年都会有 1~2 篇的发文量。另外,对于科研团队如陆伟与吴丹、王知津与韩正彪、周鹏、章成志与徐红姣、屈鹏等团队已基本形成,且不断发展与扩张,其中,作者苏新宁、章成志、侯汉清、陆伟等核心作者之间也有合作过,说明该领域作者间联系比较密切,见图 7。②持续、稳定的合作研究团队基本形成。如对于邱均平、赵捧未、王知津、韩毅等团队中成员基本形成,团队成员更新不再频繁、研究持续性较高。




图7 作者科研团队合作网络图

5 结论与展望

• 第39卷2016年第3期 •

对之间更深层次的语义关系。为此,本文提出一种基于关键词共现与语义关联相结合的主题演化分析方法。将深度学习思想引入文献计量研究中,通过 word2vec 模型将关键词表示成语义级别的词向量,然后通过 Pearson 相关系数来计算关键词之间的相关程度。通过实验证明该方法能够有效挖掘关键词间的语义关系,准确识别领域中的热点主题及发展趋势。

本文的不足之处在于:①作者之间的关联仍基于合著共现关系进行计算,需提出更有效方法来度量作者研究兴趣之间的相似性,以较深入地探测该领域中核心作者及学术合作社团之间的相互关系、变化和发展情况。②对领域主题的融合、分裂现象未作过多的探讨,需要对网络拓扑结构的形成机制进行深入研究。③本文只采用题名、关键词和摘要建模学习,训练语料的准确性有待进一步提高。下一步研究工作,主要从网络的生成机制、网络中研究热点和创新趋势的形成过程进行探究。□

参考文献

- [1] 刘向,马费成,陈潇俊,等.知识网络的结构与演化——概念与理论进展[J].情报科学,2011,29(6):801-808.
- [2] 王莉亚,张志强.基于信息熵的信息整合主题演化研究[J].图书情报工作,2012,56(6):102-106.
- [3] KIM H, HUANG M, JIN F, et al. Triple helix in the agricultural sector of Northeast Asian countries: a comparative study between Korea and China[J]. Scientometrics, 2012, 90(1): 101-120.
- [4] 安新颖.基于改进信息熵的干细胞研究领域共词分析[J].图书情报工作,2011,55(2):37-40.
- [5] 孙雨生,仇蓉蓉,黄传慧,等.国内数字图书馆个性化服务研究主题演化分析[J].情报理论与实践,2014,37(8):41-47.
- [6] 李长玲,刘非凡,魏绪秋.基于3-mode网络的领域主题演化规律分析——以知识网络研究领域为例[J].情报理论与实践,2014,37(12):104-110.
- [7] KLEINBERG J. Bursty and hierarchical structure in streams[J]. Data Mining & Knowledge Discovery, 2003, 7(4): 373-397.
- [8] KE W, BORNER K, VISWANATH L. Major information visualization authors, papers and topics in the ACM library[C]// Proceedings of the IEEE Symposium on Information Visualization. Washington, DC, USA: IEEE Computer Society, 2004: 10-12.
- [9] 王莉亚.基于关键词突变的主题突变研究[J].情报理论与实践,2013,36(11):45-48.
- [10] 赵蓉英,郭凤娇,赵月华.科学计量学主流研究领域与热点前沿研究[J].图书情报工作,2015,59(2):66-74.
- [11] SMALL H. Tracking and predicting growth areas in science[J]. Scientometrics, 2006, 68(3): 595-610.
- [12] MIKOLOV T, SUTSKEVER I, CHEN K, et al. Distributed representations of words and phrases and their compositionality[C]// Advances in Neural Information Processing Systems. Nevada, United States: Neural Information Processing Systems Foundation, 2013: 3111-3119.
- [13] BENGIO Y, DUCHARME R, VINCENT P, et al. A neural probabilistic language model[J]. Journal of Machine Learning Research (JMLR), 2003(3): 1137-1155.
- [14] 马成龙,姜亚松,李艳玲,等.基于词向量相似度的短文本分类[J].山东大学学报:理学版,2014,49(12):18-22.
- [15] 刘启元,叶鹰.文献题录信息挖掘技术方法及其软件 SATI 的实现——以中外图书情报学为例[J].信息资源管理学报,2012,2(1):50-58.
- [16] CALLON M, COURTIAL J, LAVILLE F. Co-word analysis as a tool for describing the network of interactions between basic and technological research: the case of polymer chemistry[J]. Scientometrics, 1991, 22(1): 155-205.
- [17] POLZEHL J, SPOKOINY V. Propagation-separation approach for local likelihood estimation[J]. Probability Theory and Related Fields, 2006, 135(3): 335-362.
- [18] 叶春蕾,冷伏海.基于共词分析的学科主题演化方法改进研究[J].情报理论与实践,2012,35(3):79-82.
- [19] 张斌贤,陈瑶,祝贺,等.近三十年我国教育知识来源的变迁——基于《教育研究》杂志论文引文的研究[J].教育研究,2009(4):17-25.
- [20] 吴明智,高硕,杨错.基于关键词词频和 g 指数的高校图书馆学科服务研究热点分析[J].医学信息学杂志,2013,34(1):61-64.
- [21] 杨爱青,马秀峰,张凤燕,等.g 指数在共词分析主题词选取中的应用研究[J].情报杂志,2012,31(2):51-55.
- [22] 王春秀,冉美丽.学科主题演化定量分析的理论基础探析[J].现代情报,2008(6):48-50.

作者简介:巴志超,男,1990年生,硕士生。研究方向:数据挖掘,信息检索。通讯作者。
 杨子江,男,1971年生,研究员。研究方向:知识管理,信息技术服务。
 朱世伟,男,1981年生,助理研究员。研究方向:数据挖掘,信息抽取。
 王蕾,女,1982年生,副研究员。研究方向:数字图书馆建设,信息服务。

收稿日期:2015-09-07